

Rapport SAE – Régression sur des données réelles

Introduction

Ce projet vise à développer un modèle prédictif des prix de vente immobiliers dans le département des Deux-Sèvres en 2025. Avec des données d'entraînement, ce situant dans le fichier train.csv et test.csv, ce fichier contient toutes les données des biens mais surtout son prix. Ces données nous permettent d'adapter au mieux notre modèle et de se rapprocher au maximum du prix. Le fichier to_predict.csv quant à lui contient uniquement les informations sur les biens. Notre but rendre un fichier prédiction avec l'ID du bien et sa valeur foncière. Cependant ces prédilections doivent se faire avec un modèle linéaire. Voici nous recherches menées.

Analyse menée (voir graphique à la fin)

Avant toute modélisation, une analyse des données est nécessaire. Cette analyse nous a permis d'identifier les variables qui ont une répercussion sur la valeur d'un bien.

Tout d'abord, nous avons analyse la variable de la valeur foncière. Cette variable possède une dispersion importante. Cependant la majorité des transactions se passe entre 100 000€ et 200 000€. Des valeurs bien supérieur rendent la prédilections complexe.

Pour réduire cet écart, nous avons décidé de transformer les valeurs avec le logarithme. Cela nous a permis de stabiliser la variance mais surtout d'établir une relation linéaire entre la surface bâtier et le prix. En effet nous avons constaté un lien entre la surface bâtier et le prix. Pour ce qui concerne la surface terrain, cette variable n'influe pas ou peu le prix. Nous avons décidé de ne pas s'en servir.

D'autre variable influence notre modèle, notamment le type du bien, le prix d'une maison n'est pas le même que le prix d'un appartement. Les deux variables ont des tranches de prix bien différentes. La localisation influence également le prix. Chaque zone géographique a un prix différent.

Les saisons (date mutation) n'ont pas d'influence sur le prix. C'est pour toute ces raisons que nous avons segmenté notre modélisation avec les codes postaux et le type de bien. Ces segmentations nous paraissent essentielle pour prédire au mieux le prix.

Modèle retenu

Nous avons retenu un modèle de régression linéaire logarithmique. Voici notre formule : $\log(\text{prix}) = a + b * \log(\text{surface})$. Si l'on revient à la première échelle voici la formule : $\text{prix} = e^a \times \text{surface}^b$. Ce modèle permet de faire évoluer le prix en fonction de la surface. On estime a et b par des calculs qui utilise la covariance et la variance. Pour obtenir la prédilection finale, il suffit de revenir à notre première échelle.

Nous avons choisi le modèle logarithmique car nous avons observé que la relation prix/surface n'est pas linéaire. Un bien peut doubler la surface, le prix ne double pas.

Après avoir testé différents modèles nous avons trouvé que la relation est mieux capturée par un modèle log-log que par une droite classique ou autre modèle.

La segmentation selon le type de biens a été faite. Cela permet de considérer la différence de prix au m² entre appartement et maison, la surface bâtie et la localisation.

Un modèle par code postal car les variations de prix sont énormes selon la localisation. Des modèles distincts ont été établis pour chaque code postal répertoriant au moins 5 ventes dans le fichier *train.csv*.

Puis enfin un modèle global, car certaines communes ne possèdent pas de vente ou peu de ventes. Ce modèle est basé sur l'ensemble des ventes pour chaque type de bien acheté (appartement ou maison). Celui-ci garantit qu'aucune observation ne reste sans prédiction.

Résultat (train.csv):

SCR (Erreur quadratique) : 19 916 846 445 324

R (Corrélation) : 0.7488

R² (Coefficient de détermination) : 0.5608

MAE (Erreur absolue moyenne) : 44 525 €

Un R² de 0.5608 indique que le modèle explique environ un peu plus de la moitié de la variance des prix. MAE de 44 525 € reste acceptable dans un contexte où les prix s'étendent sur une large plage.

Conclusion :


Cette régression a permis de construire un modèle de prédiction de prix immobiliers « fiable, interprétable et adapté aux contraintes techniques ». En combinant la transformation log-log, une segmentation par type de bien et une modélisation géographique au niveau du code postal.

Des pistes d'amélioration ont été identifiées pour des travaux futurs :


- Intégrer la surface du terrain et le nombre de pièces pour affiner les estimations
- Exploiter l'année de construction pour tenir compte des éventuels travaux à prévoir

GRAPHIQUES :


Distribution de la Valeur Foncière




Valeur foncière vs Surface réelle bâtie



ln(Valeur foncière) vs ln(Surface)



Valeur foncière selon le type de bien



Valeur foncière : Niort vs Autres zones

